

Предикција pIC50 активности EGFR инхибитора

Лазар Савић

Курс: Машинско учење, Математички факултет



Циљ

- Развити моделе за предвиђање биолошке активности молекула на основу њихове хемијске структуре



Циљ

- Развити моделе за предвиђање биолошке активности молекула на основу њихове хемијске структуре
- Биолошка активност се квантификује уз помоћ величине **IC50**



Циљ

- Развити моделе за предвиђање биолошке активности молекула на основу њихове хемијске структуре
- Биолошка активност се квантификује уз помоћ величине **IC50**
- IC50 (*Half Maximal Inhibitory Concentration*) – концентрација супстанце потребна за постизање 50% инхибиције одређеног биолошког процеса



Циљ

- Развити моделе за предвиђање биолошке активности молекула на основу њихове хемијске структуре
- Биолошка активност се квантификује уз помоћ величине **IC50**
- IC50 (*Half Maximal Inhibitory Concentration*) – концентрација супстанце потребна за постизање 50% инхибиције одређеног биолошког процеса
- Ниже вредности IC50 указују на већу потентност молекула



Циљ

- Развити моделе за предвиђање биолошке активности молекула на основу њихове хемијске структуре
- Биолошка активност се квантификује уз помоћ величине **IC50**
- IC50 (*Half Maximal Inhibitory Concentration*) – концентрација супстанце потребна за постизање 50% инхибиције одређеног биолошког процеса
- Ниже вредности IC50 указују на већу потентност молекула
- Због једноставније скале, бавићемо се предикцијом **pIC50** вредности

$$pIC50 = -\log_{10} IC50$$

Скуп података

- ChEMBL – база биоактивних једињења из литературе и assay експеримената



Скуп података

- ChEMBL – база биоактивних једињења из литературе и assay експеримената
- Изабране су молекулске структуре за које постоје експериментално одређене вредности активности према циљном протеину EGFR (енг. *Epidermal Growth Factor Receptor*)



Скуп података

- ChEMBL – база биоактивних једињења из литературе и assay експеримената
- Изабране су молекулске структуре за које постоје експериментално одређене вредности активности према циљном протеину EGFR (енг. *Epidermal Growth Factor Receptor*)

Атрибут	Пример
ChEMBL ID	CHEMBL25
SMILES	<chem>CC(=O)Oc1cccc1C(=O)O</chem>
Standard Type	IC50
Standard Value	14.0
Standard Units	nM
Standard Relation	'=', '>', '<'

Обрада података




Конверзија репрезентације молекула

SMILES


CC(=O)Oc1cccc1C(=O)O




Конверзија репрезентације молекула



Конверзија репрезентације молекула



Конверзија репрезентације молекула



Подела скупа података

- Подела на тренинг, валидациони и тест скуп заснована је на Мурковим скелетима (енг. *Murcko scaffold*)




Подела скупа података

- Подела на тренинг, валидациони и тест скуп заснована је на Мурковим скелетима (енг. *Murcko scaffold*)
- Мурков скелет представља структурно језгро молекула које се добија издвајањем основног система прстенова и веза које их повезују, при чему се бочне функционалне групе и терминални делови молекула уклањају




Подела скупа података


- Подела на тренинг, валидациони и тест скуп заснована је на Мурковим скелетима (енг. *Murcko scaffold*)
- Мурков скелет представља структурно језгро молекула које се добија издвајањем основног система прстенова и веза које их повезују, при чему се бочне функционалне групе и терминални делови молекула уклањају



Молекул А



Киназолин



Молекул Б

Подела према скелетима — зашто?

- Сви молекули са истим Мурковим скелетом → исти подскуп (train/val/test)



Подела према скелетима — зашто?

- Сви молекули са истим Мурковим скелетом → исти подскуп (train/val/test)
- Код случајне поделе, молекули са истим језгром се могу наћи и у тренинг и у тест скупу → прецењена тачност



Подела према скелетима — зашто?

- Сви молекули са истим Мурковим скелетом → исти подскуп (train/val/test)
- Код случајне поделе, молекули са истим језгром се могу наћи и у тренинг и у тест скупу → прецењена тачност
- Подела према скелетима = реалистичнија процена: модел се тестира на структурно новим молекулама



Предиктивни модели

- **Задатак:** регресија — предикција plC50 вредности из Morgan fingerprint-a

Модел	Улога
<i>Ridge</i>	линеарни референтни модел
<i>Random Forest</i>	ансамбл стабала
<i>LightGBM</i>	градијентно појачавање



Тренирање

- Метрика за избор: **RMSE** на валидационом скупу



Тренирање

- Метрика за избор: **RMSE** на валидационом скупу
- *Ridge*
 - једностепена *grid* претрага (10 конфигурација)



Тренирање

- Метрика за избор: **RMSE** на валидационом скупу
- *Ridge*
 - једностепена *grid* претрага (10 конфигурација)
- *Random Forest & LightGBM*
 - двостепена претрага: груба → фина мрежа око најбољег кандидата
 - *Random Forest* – 24 грубе и 24 fine конфигурације
 - *LightGBM*: *early stopping* током тренирања – 32 грубе и 27 финих конфигурација



Тренирање

- Метрика за избор: **RMSE** на валидационом скупу
- *Ridge*
 - једностепена *grid* претрага (10 конфигурација)
- *Random Forest & LightGBM*
 - двостепена претрага: груба → фина мрежа око најбољег кандидата
 - *Random Forest* – 24 грубе и 24 fine конфигурације
 - *LightGBM: early stopping* током тунинга – 32 грубе и 27 финих конфигурација
- Финални модел
 - рефит на тренинг и валидационом скупу заједно, са најбољом конфигурацијом хиперпараметара
 - коначна евалуација модела на тест скупу

Резултати

- Метрике на тест скупу

Модел	RMSE	MAE	R^2	Пирсон
<i>Ridge</i>	1,03	0,80	0,43	0,67
<i>Random Forest</i>	0,89	0,65	0,58	0,77
<i>LightGBM</i>	0,91	0,67	0,55	0,75



Упоређивање са резултатима из литературе

Рад	Репрезентација	Модел	Подела	MAE	RMSE	R^2	Корелација
<i>Gupta et al.</i>	2D дескриптори	Extra Trees	случајна	0,61	0,89	0,67	0,82
<i>Akinnusi et al.</i>	ECFP + дескриптори	Extra Trees	скафолд	-	$0,90 \pm 0,02$	$0,55 \pm 0,01$	$0,74 \pm 0,02$
Овај рад	Morgan fingerprint	Random Forest	скафолд	0,65	0,89	0,58	0,77



Хвала на пажњи!

