

УНИВЕРЗИТЕТ У БЕОГРАДУ
МАТЕМАТИЧКИ ФАКУЛТЕТ



Лазар Савић

РАЗВОЈ СОФТВЕРА ЗА ОТКРИВАЊЕ МОЛЕКУЛСКИХ СТРУКТУРА СА ПОТЕНЦИЈАЛНО ЛЕКОВИТИМ ДЕЈСТВОМ

мастер рад

Београд, 2026.

Ментор:

проф. др Јована КОВАЧЕВИЋ, редован професор
Универзитет у Београду, Математички факултет

Чланови комисије:

др Мирјана МАЉКОВИЋ РУЖИЧИЋ, ванредни професор
Универзитет у Београду, Математички факултет

Стефан КАПУНАЦ, асистент
Универзитет у Београду, Математички факултет

Датум одбране: _____

Порогици

Наслов мастер рада: Развој софтвера за откривање молекулских структура са потенцијално лековитим дејством

Резиме: Развој нових лекова представља сложен процес који захтева значајне временске и финансијске ресурсе. Примена метода рачунарске интелигенције омогућава аутоматизацију и оптимизацију појединих корака у процесу откривања нових лековитих једињења, чиме се смањује потреба за испитивањем великог броја молекула традиционалним експерименталним приступима.

У овом раду представљен је развој софтверског система за генерисање, евалуацију и оптимизацију молекулских структура са потенцијално лековитим дејством. Као основни приступ за претраживање простора могућих молекула коришћени су генетски алгоритми, уз примену различитих функција погодности за процену квалитета генерисаних структура. Систем омогућава примену оператора селекције, мутације и рекомбинације, као и праћење и анализу процеса оптимизације.

За развој система коришћен је програмски језик Python. Графички кориснички интерфејс реализован је употребом библиотеке PyQt, док је за обраду и анализу молекулских структура коришћена библиотека RDKit. За тестирање система коришћени су подаци из јавно доступне базе биоактивних молекула ChEMBL.

Развијени систем представља пример примене рачунарске интелигенције у области рачунарски потпомогнутог откривања лекова и омогућава ефикасније претраживање простора молекулских структура у циљу идентификације потенцијалних кандидата за даља фармаколошка истраживања.

Кључне речи: рачунарска интелигенција, генетски алгоритми, откривање лекова, молекулске структуре

Садржај

1	Увод	1
1.1	Примери коришћења класичних L ^A T _E X елемената	1
2	Репрезентација молекула у програмима	3
2.1	SMILES нотација	3
2.2	SELFIES нотација	5
2.3	Објекат Mol библиотеке RDKit	5
2.4	Morgan fingerprint вектори	6
3	Процена лековитости и биолошке активности	8
3.1	QED коефицијент	8
3.2	Регресиони предиктивни модели	9
4	Генетски алгоритам	14
4.1	Селекција	15
4.2	Укрштање	16
4.3	Мутација	22
5	Графички интерфејс и архитектура	26
6	Експериментални резултати	27
7	Дискусија	28
8	Закључак	29
	Литература	30

Глава 1

Увод

1.1 Примери коришћења класичних L^AT_EX елемената

Ово је реченица у којој се јавља цитат [?]. Још један цитат [?]. Испробавамо наводнике: „Рекао је да му се јавимо сутра”. У табели 1.1 која следи приказани су резултати експеримента. Ovo je primer rečenice ispisane latiničkim pismom u okviru ćirilčkog dokumenta. У овој реченици се налази једна рећ написана латиницом. Иза ове реченице следи фуснота.¹ Сајт математичког факултета је <http://www.matf.bg.ac.rs>.

Ovo je malo duži blok teksta isписан latiničkim pismom u okviru ćirilčkog dokumenta. Fiјuće vetar u šiblju, ledi pasaže i kuće iza njih i gundа u odžacima.

Ево и један пример математичке формуле: $e^{i\pi} + 1 = 0$. На слици 1.1 приказан је један графикон.


$$\int_a^b f(x) \, dx \stackrel{def}{=} \lim_{\max \Delta x_k \rightarrow 0} \sum_{k=1}^n f(x_k^*) \Delta x_k$$

Више детаља биће дато у глави ?? на страни ??.

¹Ово је фуснота.

Табела 1.1: Резултати

1	2	3
4	5	6
7	8	8



Слика 1.1: Графикон

У тезу можемо убацити и програмски код.

Ovo je doslovni tekst.

```
#include <stdio.h>

int main() {
    printf("Hello, world!\n");
    return 0;
}
```

Овај С програм се може превести помоћу преводиоца GCC [?].

Можемо правити и набрајања:

1. Анализа 1
2. Линеарна алгебра
3. Аналитичка геометрија
4. Основи програмирања

Глава 2

Репрезентација молекула у програмима

Молекулске структуре могу се представити на више различитих начина, при чему свака репрезентација наглашава одређене аспекте молекула и прилагођена је конкретној намени. Док су неке репрезентације погодне за једноставно записивање и размену података о молекулима, друге омогућавају њихову рачунарску обраду, анализу или примену у алгоритмима машинског учења. Избор одговарајуће репрезентације зависи од проблема који се решава и операција које је потребно извршити над молекулским структурама.

У овом раду коришћене су три међусобно повезане репрезентације молекула. За текстуални запис молекулских структура коришћене су SMILES нотација 2.1 и SELFIES нотација 2.2, за њихову интерну репрезентацију и манипулацију библиотека RDKit користи објекат типа Mol 2.3, док су за потребе обучавања модела машинског учења и предикције биолошке активности молекули представљени помоћу Morgan fingerprint вектора 2.4. У наставку су описане основне карактеристике сваке од наведених репрезентација и њихова улога у оквиру развијеног система.

2.1 SMILES нотација

SMILES (енг. *Simplified Molecular Input Line Entry System*) [8] представља једноставан и компактан текстуални начин представљања молекулских структура у облику ниске ASCII карактера. Због своје читљивости и мале величине записа, широко се користи за складиштење, размену и обраду података о мо-

лекулима. Иако је реч о једнодимензионом текстуалном запису, SMILES омогућава представљање структуре молекула, укључујући атоме, хемијске везе, гранања и цикличне структуре, а по потреби и информације о стереохемији. Заснива се на неколико једноставних правила записа, која ће у наставку бити описана и илустрована примерима датим у табели 2.1.

Правило 1 - Атоми: Атоми који улазе у састав молекула представљени су својим хемијским симболима, у угластим заградама. Ове заграде се изостављају за „органски” подскуп атома - В, С, N, О, Р, S, F, Cl, Br и I. Ако су заграде изостављене, подразумеван је имплицитан број водоникових атома који задовољава стандардну валенцу атома, те се у тим случајевима H атоми изостављају. Јони се увек пишу у заградама, попут $[Co^{3+}]$ или $[OH^-]$.

Правило 2 - Везе: Везе између атома представљају се на различите начине, у зависности од њихове вишеструкости. Везе између суседних атома су подразумевано једноструке, и тада се оне не наводе. Двоструке везе представљене су симболом '=', а троструке са '#'. Ароматичне везе могу се експлицитно представити симболом ':'.

Правило 3 - Гранања: У случају разгранатих молекула, грана која се издваја из родитељског ланца је одвојена обичним заградама '()'





Правило 4 - Циклуси: Циклични молекули се такође записују линеарно, тако што се позиције на којима се прстен отвара и затвара обележе истим бројем. У случају ароматичних прстена, сви атоми који учествују у том прстену обележавају се малим словима, како би се разликовали од одговарајућих алифатичних прстена.

Правило 5 - Неповезане структуре: Уколико се молекул састоји од више неповезаних компоненти, он се може представити тако што се на сваку компоненту примене правила 1 - 4, и добијени записи се повежу симболом '.'.

Важно је напоменути да SMILES запис није јединствен за један молекул. Иста молекулска структура може имати више различитих SMILES записа, у зависности од избора почетног атома и редоследа обиласка структуре. Како би се обезбедила јединствена и стандардизована репрезентација молекула, често се користи канонски SMILES запис, који алгоритамски одређује један представник за дату молекулску структуру.

2.2 SELFIES нотација

SELFIES (енг. *SELF-Referencing Embedded Strings*) [4] представља начин текстуалне репрезентације молекулских структура, сличан SMILES нотацији. За разлику од SMILES-а, код којег поједини карактери не представљају увек засебне структурне елементе, SELFIES је организован као низ јасно раздвојених токена, при чему се сваки токен записује у угластим заградама. Токени могу представљати атоме, хемијске везе и друге елементе неопходне за опис молекулске структуре. Свака синтаксно исправна SELFIES ниска одговара валидној молекулској структури, и свака молекулска структура може да се представи SELFIES ниском. Ово је значајна предност SELFIES репрезентације, јер се тиме избегавају многи случајеви невалидних структура који се могу јавити приликом директне манипулације SMILES записима. У табели 2.1 дати су примери молекулских структура и одговарајућих SELFIES записа.

Молекул	Структура	SMILES	SELFIES
Етанол		<chem>CCO</chem>	<code>[C] [C] [O]</code>
Етен		<chem>C=C</chem>	<code>[C] [=C]</code>
Изобутан		<chem>CC(C)C</chem>	<code>[C] [C] [Branch1] [C] [C] [C]</code>
Бензен		<chem>c1ccccc1</chem>	<code>[C] [=C] [C] [=C] [C] [=C] [Ring1] [=Branch1]</code>

Табела 2.1: Примери молекулских структура и одговарајућих SMILES и SELFIES записа

2.3 Објекат Mol библиотеке RDKit

RDKit (енг. *RDKit Cheminformatics Toolkit*) је open-source библиотека за рад са молекулским структурама [5]. Имплементирана је у C++-у, са Python интерфејсом, и широко се користи у областима попут хемоинформатике


и машинског учења ¹. За разлику од текстуалних формата попут SMILES-а, RDKit пружа богат интерфејс за рад са молекулима, кроз објекат Mol. Објекат Mol интерно представља молекулску структуру као граф чији су чворови атоми, а гране хемијске везе, уз додатне информације о особинама веза и атома. Оваква репрезентација омогућава ефикасно извршавање различитих операција над молекулима, као што су валидација структуре, израчунавање молекулских дескриптора, генерисање Morgan fingerprint вектора, као и визуализацију структура у корисничком интерфејсу.

2.4 Morgan fingerprint вектори

Morgan fingerprint [7] представља нумеричку репрезентацију молекулске структуре у облику бит-вектора фиксне дужине, погодну за примену алгоритама машинског учења. За разлику од SMILES записа и RDKit Mol објекта, који чувају информације о структури молекула, Morgan fingerprint издваја присуство одређених локалних структурних карактеристика молекула и кодира их у бинарни вектор. На тај начин сваки бит представља присуство или одсуство одређеног структурног мотива, што омогућава једноставну примену математичких и машинских метода над молекулским подацима (слика 2.1).

Генерисање Morgan fingerprint вектора заснива се на итеративном обиласку околине сваког атома у молекулу. За сваки атом посматрају се суседни атоми до задатог растојања, дефинисаног параметром *radius*, након чега се добијене локалне структуре хеширају и пресликавају у позиције бит-вектора. Избор вредности овог параметра представља компромис између детаљности и генерализације молекулске репрезентације. Мање вредности описују локалне карактеристике блиске појединачним атомима, док веће омогућавају кодирање сложенијих структурних фрагмената који обухватају већи део молекула.

¹Поготово у комбинацији ове две области - компјутерски потпомогнуто откривање лекова, што је и суштина овог рада.



Слика 2.1: Пример Morgan fingerprint репрезентације (аспирин): бит-вектор и подструктуре за различите радијусе. Преузето из [6].

Глава 3

Процена лековитости и биолошке активности

У оквиру развијеног система потребно је проценити лековитост, односно потенцијалну биолошку активност генерисаних молекулских структура, како би се омогућило њихово рангирање у оквиру генетског алгорита. Пошто експериментално одређивање потентности сваке новогенерисане структуре није могуће у току процеса оптимизације, искоришћени су другачији приступи који представљају брзе рачунарске апроксимације експерименталних мерења. Са једне стране, то је QED коефицијент (3.1), а са друге стране, регресиони модели машинског учења (3.2). У оба случаја, метрика коју рачунамо може да се користи као вредност фитнес функције, која се оптимизује у току генетског алгорита.

3.1 QED коефицијент

QED (енг. *Quantitative Estimate of Drug-likeness*) развили су Ричард Бикертон и сарадници [2]. Основу ове метрике чине физичко-хемијске карактеристике молекула (тј. *молекулски дескриптори*):

- моларна маса (енг. *molecular weight*, MW),
- октанол-вода партициони коефицијент (енг. *octanol-water partition coefficient*, ALOGP),
- број донора водоничних веза (енг. *hydrogen bond donors*, HBD),

- број акцептора водоничних веза (енг. *hydrogen bond acceptors*, HBA),
- поларна молекулска површина (енг. *molecular polar surface area*, PSA),
- број ротабилних веза (енг. *rotatable bonds*, ROTB),
- број ароматичних прстенова (енг. *aromatic rings*, AROM),
- број структурних упозорења (енг. *structural alerts*, ALERTS).

Рачунањем вредности ових карактеристика, одређује се у којој мери молекул поседује карактеристике типичне за успешне лекове. За сваки дескриптор, дефинисана је функција пожељности (енг. *desirability function*), која пресликава вредност дескриптора у интервал $[0, 1]$. Општи облик те функције дат је једначином (3.1).

$$d(x) = a + \frac{b}{\left[1 + \exp\left(-\frac{x-c+\frac{d}{2}}{e}\right)\right]} \cdot \left[1 - \frac{1}{\left[1 + \exp\left(-\frac{x-c-\frac{d}{2}}{f}\right)\right]}\right]. \quad (3.1)$$

Параметри a , b , c , d , e и f за сваку од функција d_{MW} , d_{ALOGP} , d_{HBD} , d_{HBA} , d_{PSA} , d_{ROTB} , d_{AROM} и d_{ALERTS} дати су у оригиналном раду [2].

Описани молекуларни дескриптори могу имати различиту важност при одређивању QED коефицијента, па се он може израчунати као *џејнсовска геометријска средина* вредности функција молекуларних дескриптора:

$$\text{QED} = \exp\left(\frac{\sum_{i=1}^n w_i \ln(d_i)}{\sum_{i=1}^n w_i}\right). \quad (3.2)$$

Добијена вредност QED коефицијента припада интервалу $[0, 1]$, при чему веће вредности указују на већу сличност молекула са познатим лековима, и самим тим, на већу погодност молекула са аспекта општих физичко-хемијских својстава.

3.2 Регресиони предиктивни модели

Основна вредност коју тренирани модели у овом раду предвиђају је IC50 (*half maximal inhibitory concentration*), која представља концентрацију супстанце потребну за постизање 50% инхибиције одређеног биолошког процеса.

Ниже вредности IC50 указују на већу потентност молекула, па се у циљу погодније примене у моделима машинског учења често користи трансформисана вредност pIC50, при чему је $pIC50 = -\log_{10}(IC50)$.

За потребе обучавања модела коришћени су подаци из јавно доступне базе биоактивних молекула ChEMBL. Изабране су молекулске структуре за које постоје експериментално одређене вредности активности према циљном протеину EGFR (*Epidermal Growth Factor Receptor*). Овај протеин је рецептор тирозинских киназа и учествује у регулацији процеса као што су раст, деоба и преживљавање ћелија. Због његове улоге у развоју и напредовању појединих малигних обољења, EGFR представља значајну мету у развоју лекова.

Припрема скупа података

Релевантни атрибути којима су описане молекулске структуре из (необрађеног) скупа података су њихов идентификатор (*Molecule ChEMBL ID*), SMILES запис, експериментална IC50 вредност (*Standard Value*) са мерном јединицом (*Standard Units*) и типом релације (*Standard Relation*). На слици 3.1 приказан је начин на који смо филтрирали сирови скуп података, као и број молекула који су остали након сваког корака филтрирања. У наставку објашњавамо сваки корак у овом процесу, који је приказан на слици 3.1.

1. Филтрирање по мерној јединици: Избачени су сви ентитети у којима мерна јединица IC50 вредности није наведена, или је изражена у јединицама различитим од nM.

2. Филтрирање по типу релације: У неким случајевима експериментално мерење не даје тачну вредност IC50, већ само доњу или горњу границу измерене вредности. Из тог разлога, како би се користиле само егзактне нумеричке вредности погодне за регресију, искључени су сви редови у којима тип релације недостаје, или је различит од једнакости.

3. Филтрирање по вредности: Остављени су само они редови у којима је IC50 вредност позитивна.

4. Филтрирање по SMILES запису: Остављени су само они записи у којима је SMILES запис молекула валидан. Исправност SMILES записа проверавамо помоћу библиотеке RDKit, тако што испитујемо да ли је могуће успешно конструисати Mol објекат на основу датог записа. За сваки преостали ред одређена је циљна вредност pIC50 трансформацијом IC50 вредности.

5. Агрегација поновљених мерења: Како би сваки молекул имао једну јединствену циљну вредност, извршено је груписање записа према идентификатору молекула. За сваки молекул задржана је максимална измерена pIC_{50} вредност, јер она представља највећу забележену потентност тог молекула у доступним експерименталним мерењима. Овакав приступ је у складу са каснијом употребом у генетском алгоритму, где веће pIC_{50} вредности представљају бољи резултат оптимизације. Иако оправдан са становишта циља рада, овај приступ може довести до благо оптимистичне процене активности у случајевима када постоји већи број различитих мерења за исти молекул.



Слика 3.1: Поступак филтрирања и агрегације скупа података

Након примене свих наведених корака добијен је коначан скуп од 10834 јединствених молекулских структура, који је коришћен за даљу обраду и обучавање предиктивних модела.

Формирање улазне репрезентације молекула

Формирани скуп података садржи молекулске структуре представљене у облику SMILES записа и одговарајуће pIC_{50} вредности. Међутим, текстуални

запис молекула није директно погодан за примену већине алгоритама машинског учења, који захтевају нумеричку репрезентацију улазних података.

За сваки молекул из коначног скупа, SMILES запис је најпре конвертован у Mol објекат библиотеке RDKit (2.3). Након тога, над добијеним Mol објектима генерисани су Morgan fingerprint вектори (2.4). У овом раду коришћени су бинарни вектори дужине 2048 бита, са параметром *radius* једнаким 2, узимајући притом у обзир хиралност молекула. Коришћена вредност параметра *radius* одговара ECFP4 конфигурацији [7]. На овај начин, добијена је бинарна матрица димензија 10834×2048 , чије вредности представљају улазне атрибуте регресионих модела, док pIC₅₀ вредност представља циљну променљиву коју модели уче да предвиде.

Контролом квалитета утврђено је да се 10834 јединствених молекулских структура пресликало у 10674 различита Morgan fingerprint вектора. То значи да је приближно 1.5% молекула имало идентичну бинарну репрезентацију. Оваква појава је очекивана и представља последицу фиксне дужине и начина хеширања структурних карактеристика.

Подела на тренинг, валидациони и тест скуп

Након формирања нумеричке репрезентације молекула, скуп података је подељен на тренинг, валидациони и тест скуп. Тренинг скуп коришћен је за обучавање регресионих модела, валидациони скуп за избор одговарајућих хиперпараметара и поређење модела током развоја, док је тест скуп коришћен за коначну процену перформанси одабраних модела.

Уместо случајне поделе молекула, коришћена је подела заснована на Мурковим скафолдима (енг. *Murcko scaffold*) [1]. Murcko scaffold представља структурно језгро молекула које се добија издвајањем основног система прстенова и веза које их повезују, при чему се бочне функционалне групе и терминални делови молекула уклањају. Молекули са истим или веома сличним структурним језгром на тај начин могу бити сврстани у исту групу. На слици 3.2 приказан је пример два таква молекула, који имају заједнички скафолд у виду киназолинског језгра.

Приликом поделе, сви молекули који припадају истом скафолду задржани су у истом подскупу. На овај начин се спречава да веома сличне молекулске структуре истовремено буду присутне у тренинг и тест скупу, што би код случајне поделе могло довести до прецењивања способности модела да



Слика 3.2: Молекули А и Б са истим скафолдом у виду киназолинског језгра

предвиђа активност структурно различитих молекула. Скафолд подела стога представља реалистичнију процену способности модела да генерализује на молекулске структуре које нису биле присутне у процесу обучавања.

Циљ је био да приближно 80% молекула припада тренинг скупу, а по 10% валидационом и тест скупу. Пошто се додељују целе скафолд групе, а не појединачни молекули, коначни број записа у сваком подскупу би могао да незнатно одступа од циљаног односа. У нашем случају, добијене пропорције одговарају циљаним, а конкретне кардиналности ових скупова дате су у табели 3.1.

Скуп	Број молекула	Удео [%]
Тренинг	8 667	80,0
Валидациони	1 083	10,0
Тест	1 084	10,0

Табела 3.1: Подела на тренинг, валидациони и тест скуп

Истренирани модели

Ridge регресија

Random Forest

LightGBM

Резултати и упоредна анализа

Глава 4

Генетски алгоритам

Генетски алгоритми представљају једну од метахеуристичких метода за решавање оптимизационих проблема. Инспирисани су принципима природне еволуције и Дарвиновом теоријом природне селекције. Основна идеја је да се процес оптимизације посматра као аналоган еволуцији популације живих организама. Уместо једног решења, алгоритам одржава популацију потенцијалних решења. Свако решење представљено је на одговарајући начин, а његов квалитет се процењује помоћу функције прилагођености (тј. фитнес функције). На основу квалитета решења врши се селекција, при чему се квалитетнијим јединкама даје већа вероватноћа избора за стварање наредне генерације. Над изабраним јединкама примењују се генетски оператори *укрштања* и *мутације*. Укрштањем се комбинују карактеристике постојећих решења, док мутација уводи случајне измене (са одређеном вероватноћом) и тиме одржава разноврсност популације.

Након примене ових оператора формира се нова генерација, која се поново процењује, а поступак се итеративно понавља. На тај начин се популација постепено усмерава ка квалитетнијим решењима. Истовремено, генетски алгоритам настоји да одржи равнотежу између *експлоатације* већ пронађених добрих решења и *исстраживања* нових области простора претраге. Алгоритам се обично зауставља након одређеног броја генерација, достизања задатог квалитета или када више не долази до значајног побољшања решења.

У контексту проблема откривања молекулских структура са потенцијално лековитим дејством, простор могућих молекулских структура је дискретан и комбинаторно огроман, што отежава примену класичних градијентних метода оптимизације. Због тога се еволутивна претрага поставља као природан избор,

па је потребно описати начин на који се општи принципи генетског алгорита прилагођавају овом проблему.

Свака јединка у популацији представљена је помоћу репрезентација описаних у поглављу 2 — пре свега SMILES записом и RDKit Mol објектом, уз Morgan fingerprint векторе када је потребна предикција активности. Прилагођеност сваке јединке процењује се метрикама из поглавља 3. Кориснику је омогућен избор функције прилагођености, почетне популације, броја генерација и осталих параметара генетског алгорита (што ће бити описано у поглављу 5). У наставку поглавља биће објашњени оператори селекције, укрштања и мутације који се користе у оквиру развијеног система.

4.1 Селекција

Селекција одређује које ће јединке из тренутне популације бити изабране за родитеље приликом стварања нових јединки укрштањем. На основу вредности функције прилагођености, квалитетније јединке имају већу вероватноћу да буду изабране. Истовремено, стохастичка природа селекције омогућава очување разноврсности популације и смањује могућност њеног прераног усмеравања ка малом броју сличних структура. У развијеном систему подржана су два начина селекције: турнирска и рулетска селекција.

Турнирска селекција. Приликом турнирске селекције, из популације се случајно бира k јединки, где k представља *величину турнира* (*tournament size*). Од изабраних јединки за родитеља се бира она са највећом вредношћу функције прилагођености. Већа вредност параметра k повећава селекциони притисак, јер квалитетније јединке имају већу предност у односу на остале, док мања вредност омогућава очување веће разноврсности популације.

Рулетска селекција. Код рулетске селекције, вероватноћа избора сваке јединке одређује се на основу њеног удела у укупној вредности функције прилагођености популације. Јединке са већим вредностима функције прилагођености имају већи удео у укупној вероватноћи избора и самим тим имају већу вероватноћу да буду изабране. Избор се реализује генерисањем случајне вредности и одређивањем јединке на основу кумулативне расподеле вероватноћа, по принципу рулетског точка.

Елитизам. Поред избора родитеља, у свакој генерацији примењује се и *ели-тизам*. Најбољих e јединки из претходне генерације, према вредности функције прилагођености, преноси се непосредно у наредну генерацију, без примене укрштања и мутације. На тај начин се гарантује да најбоља до тада пронађена решења неће бити изгубљена услед стохастичке природе генетских оператора. Преостала места у популацији попуњавају се новим јединкама добијеним применом селекције, укрштања и мутације.

4.2 Укрштање

Укрштање је генетски оператор којим се из два родитељска молекула генеришу потомачке структуре комбиновањем њихових делова. У контексту молекулских структура, циљ укрштања није само механичко комбиновање две структуре, већ генерисање хемијски валидних молекула који наслеђују одређене структурне карактеристике родитеља и истовремено проширују простор претраге.

За разлику од класичних генетских алгоритама над нумеричким или бинарним представама, код молекула није могуће произвољно комбиновати делове њихове репрезентације и очекивати валидан резултат. Због тога сваки од имплементираних оператора укрштања укључује поступак провере исправности добијених структура, а у случају неуспешног укрштања омогућава се поновни покушај са другим случајно изабраним деловима родитељских структура.

Након избора родитеља, они се упарују и над сваким паром се примењује одабрани оператор укрштања. У развијеном систему подржана су четири начина укрштања:


1. **SMILES укрштање** — укрштање на нивоу текстуалног SMILES записа;
2. **SELFIES укрштање** — укрштање на нивоу SELFIES токена;
3. **Графовско укрштање** — укрштање директно над молекулским графом;
4. **BRICS укрштање** — укрштање на нивоу хемијски дефинисаних молекулских фрагмената.

Наведени оператори се међусобно разликују пре свега по начину представљања молекула и нивоу на којем се врши њихова рекомбинација. У наставку је за сваки оператор описан поступак избора делова родитељских структура, њиховог комбиновања и провере добијених потомака.

SMILES укрштање

SMILES укрштање се извршава директно над текстуалним записима молекулских структура, без било каквог разматрања детаља саме структуре. Подржане су две врсте укрштања: једнопозиционо и двопозиционо.


Код једнопозиционог укрштања, за сваки од два родитељска SMILES записа насумично се бира по једна позиција пресека, при чему се пресек не поставља на почетак или крај ниске. Ниске се затим раздвајају на два дела и комбинују тако да први потомак садржи почетни део првог родитеља и завршни део другог родитеља, док други потомак настаје обрнутом комбинацијом. На овај начин добијају се две нове SMILES ниске, које се затим проверавају помоћу RDKit библиотеке како би се утврдило да ли представљају валидне молекулске структуре. Поступак избора позиција и формирања потомака приказан је на слици 4.1.



Слика 4.1: Једнопозиционо укрштање SMILES ниски

Уколико након унапред дефинисаног броја покушаја није могуће добити два валидна потомка једнопозиционим укрштањем, прелази се на двопозиционо укрштање. У овом случају се у сваком родитељском SMILES запису бирају по две различите позиције пресека. Део ниске између изабраних позиција једног родитеља замењује се одговарајућим делом другог родитеља, чиме се добијају два потомка. И у овом случају валидност добијених SMILES записа проверава се помоћу RDKit библиотеке. Пример двопозиционог укрштања приказан је на слици 4.2.

Иако веома једноставан и брз, овакав поступак има велику ману. Насумичним пресецањем SMILES ниски веома често долази до формирања нева-



Слика 4.2: Двопозиционо укрштање SMILES ниски

лидних SMILES записа. То илуструје слика 4.1, где су добијена два невалидна потомка, док се двопозиционим укрштањем приказаним на слици 4.2 добијају два валидна потомка. Да би се овај негативни ефекат ублажио, поступак се понавља велики број пута, али чак ни тада нема гаранције да ће се добити валидне структуре. Ако се ни након неколико хиљада покушаја не добију валидни потомци, родитељске SMILES ниске се пропуштају у неизмењеном облику у наредну генерацију.

SELFIES укрштање

Укрштање над SELFIES нискама реализовано је на сличан начин као једнопозиционо укрштање над SMILES нискама, при чему се размена делова родитељских структура врши на нивоу SELFIES токена. За разлику од SMILES укрштања, код којег се пресечне позиције бирају међу појединачним карактерима ниске, код SELFIES укрштања пресечне позиције се бирају између токена. На тај начин се спречава раздвајање појединачних SELFIES токена, који могу садржати више карактера. Поступак почиње енкодирањем SMILES записа родитеља у SELFIES ниске, након чега следи избор пресечних позиција. Потомци се потом формирају разменом завршних делова родитељских низова токена. Први потомак добија почетни део првог родитеља и завршни део другог родитеља, док други потомак добија почетни део другог родитеља и завршни део првог родитеља. Добијени низови токена се затим спајају у SELFIES ниске и декодирају у SMILES репрезентацију.

Укрштање графова

Графовско укрштање врши рекомбинацију директно над молекулским графом, односно над Mol објектима библиотеке RDKit. За разлику од укрштања над текстуалним репрезентацијама, код овог приступа место пресецања одре-

Ћује се на основу структуре молекула, чиме се омогућава директна манипулација атомима и хемијским везама.


Поступак укрштања започиње случајним избором једне везе из сваког родитељског молекула. Као кандидати за пресецање разматрају се искључиво ацикличне везе, тј. везе које нису део ниједног прстена. Овим ограничењем се избегава директно пресецање цикличних структура и гарантује се раздвајање молекулских графова на два одвојена фрагмента. На слици 4.3 приказан је начин укрштања два родитељска молекула - А и Б. Посебно су означене везе које су изабране за пресецање, а настали фрагменти означени су са А1, А2, Б1 и Б2.

Атоми који су градили пресечену везу се затим повезују помоћним, односно *dummy* атомима. Они означавају места на којима је могуће поново повезати настале фрагменте. На слици 4.3, ти атоми означени су симболом *.

Добијени фрагменти се затим укрштају тако што се по један фрагмент првог родитеља спаја са фрагментом другог родитеља, и обрнуто (на тај начин, спајамо фрагменте А1 и Б2, односно А2 и Б1). Два фрагмента се комбинују тако што се њихови *dummy* атоми уклоне, а атоми који су били њихови суседи повежу се једноструком хемијском везом. Једнострука веза је изабрана као најсигурнија опција за поновно повезивање, јер гарантовано неће нарушити валенце атома који се повезују, а тиме и валидност новодобијених структура. У примеру приказаном на слици, на тај начин добијамо структуре А1Б2 и А2Б1.

BRICS укрштање

BRICS (енг. *Breaking of Retrosynthetically Interesting Chemical Substructures*) [3] представља метод за декомпозицију молекула на мање структурне фрагменте раскидањем оних веза које се често могу формирати у реакцијама синтезе. За разлику од једноставног пресецања SMILES ниске на одређеној позицији, BRICS декомпозиција узима у обзир хемијско окружење атома који учествују у вези. Метод дефинише 16 различитих типова хемијских окружења, који су на слици 4.4 приказани ознакама од L1 до L16. На овој слици, свака линија између фрагмената означава да се они могу повезати хемијском везом током неке познате хемијске реакције, тј. да су *компатибилни*. Приликом декомпозиције, везе између компатибилних типова окружења могу бити прекинуте, чиме се добијају фрагменти који на местима прекида садрже озна-



Слика 4.3: Схема графовског укрштања: пресецање ацикличних веза, формирање и рекомбинација фрагмената


ке које одређују њихов BRICS тип. Те ознаке представљају места на којима фрагмент може поново да се повеже са неким другим компатибилним фрагментом.

У оквиру генетског алгорита, BRICS укрштање најпре декомпонује оба родитељска молекула применом BRICS правила. Добијени фрагменти се затим третирају као градивни елементи родитељских структура. Сваки од родитељских скупова фрагмената се партиционише на два подскупа, након чега се изврши рекомбинација ових партиција. Другим речима, ако су фрагменти првог родитеља подељени на скупове F_1^A и F_1^B , а фрагменти другог родитеља на F_2^A и F_2^B , скупови потомачких фрагмената C_1 и C_2 се формирају као:

$$C_1 = F_1^A \cup F_2^B,$$

$$C_2 = F_2^A \cup F_1^B.$$

Тако добијени скупови прослеђују се поступку BRICS реконструкције, који покушава да повеже компатибилне фрагменте. Пошто се фрагменти једног



Слика 4.4: BRICS типови окружења (L1 - L16) и дозвољене везе између компатибилних фрагмената. Преузето из [3].

скупа могу повезивати на различите начине, реконструкција може произвести велики број различитих молекулских структура. У имплементацији у овом раду не врши се потпуна еnumerација свих могућих структура, већ се разматра ограничен број генерисаних кандидата, након чега се један од њих насумично бира као потомак.

Важна особина BRICS укрштања је то што се заснива на хемијски мотивисаним правилима, захваљујући којима се добијају хемијски смислени фрагменти који могу представљати реалне градивне блокове за синтезу. Приликом њихове рекомбинације поштују се правила о међусобно компатибилним типовима фрагмената, чиме се повећава вероватноћа да ће добијене молекулске структуре бити синтетички доступне. Ово је значајна предност у откривању нових молекула, јер поред њихових жељених својстава треба узети у обзир и практичну изводљивост синтезе.

4.3 Мутација

Мутација је генетски оператор који уводи случајне измене у структуру појединачних јединки и на тај начин доприноси одржавању разноврсности популације. За разлику од укрштања, које комбинује структурне делове два родитеља, мутација делује на једној јединки и омогућава истраживање нових молекулских структура које не морају бити директна комбинација родитељских структура.


У развијеном систему мутација се примењује на сваког потомка након укрштања, са задатом вероватноћом. Као и у случају укрштања, подржана су четири типа мутација: **SMILES**, **SELFIES**, **графовска** и **BRICS** мутација. Избор режима мутације врши се независно од режима укрштања, што омогућава произвољно комбиновање различитих приступа, попут **SELFIES** укрштања са **SMILES** мутацијом. Сви оператори настоје да очувају хемијску валидност добијених молекула. У имплементираним систему, уколико изабрани тип мутације није могуће применити на конкретну јединку, или пак он не доводи до валидне структуре, примењује се резервна, **SMILES** мутација. Оператори мутације су на тај начин повезани у ланац резервних поступака, при чему се у крајњем случају користе једноставније **SMILES** операције, чија је успешност извршавања загарантована.

SMILES мутација

SMILES мутација подразумева директну манипулацију **SMILES** ниском, изменом њених специфичних делова. Подржана су четири типа **SMILES** мутација: замена хетероатома, замена функционалних група, делеција и инсерција. У случају да систем одлучи да изврши **SMILES** мутацију, на случајан начин, са једнаким вероватноћама, бира се један од наведених конкретних типова.

Замена хетероатома (атома различитих од угљеника и водоника) реализована је тако што се пронађу све позиције хетероатома у **SMILES** ниски, а онда се за произвољно одабрану позицију врши замена тог хетероатома другим хетероатомом. Скуп ових прелаза је унапред дефинисан, и једноставности ради, ограничен је на атоме кисеоника, азота, сумпора и фосфора. Граф прелаза једног атома у други приказан је на слици 5.1, при чему тежине грана означавају вероватноћу преласка једног атома у други. Битно је нагласити

да су прелази дефинисани тако да не нарушавају валидност новодобијеног молекула. Овакав тип мутације није могуће применити на молекуле који не садрже хетероатоме.



Слика 4.5: Граф прелаза између хетероатома и њихове вероватноће

Замена функционалних група заснива се на испитивању присуства одређених функционалних група у молекулу. Функционалне групе су специфични делови молекула који диктирају његово хемијско понашање, тј. типове реакција у које ступа, али и физичка својства. Због тога је смислено мутирати овакве делове молекула. Конкретно, омогућена је замена карбонилне групе карбоксилном, карбоксилне групе амидном, карбонилне групе аминоксидном, као и нитрилне групе алдехидном. Такође, омогућена су формирања етарске или кето функционалне групе између два суседна атома угљеника, али и продужетак угљеничног ланца. Постојањем последње наведене мутације, повећава се могућност генерисања бар једног кандидата за мутацију, чак и у случајевима када молекул не садржи неку од специфичних функционалних група које су предмет осталих дефинисаних замена. За сваку дефинисану промену и свако њено појављивање у SMILES ниски, формира се по један кандидат, при чему се мења само конкретно појављивање функционалне групе. Од свих тако добијених кандидата, један се насумично одабира и користи као резултат мутације.

Делеција се реализује уклањањем одређеног дела SMILES ниске. Најпре се испитује да ли SMILES ниска садржи гранања, при чему се гранање посматра као подниска ограничена одговарајућим упареним заградама. Уколико гранања постоје, насумично се бира једно од њих и покушава се његово уклањање. Уколико молекул не садржи гранања или ниједан покушај њиховог уклањања не резултује валидном SMILES ниском, прелази се на покушај брисања појединачног атома са насумично одабране позиције. Након сваког покушаја

проверава се валидност добијене структуре, а поступак се понавља до унапред дефинисаног броја покушаја. Уколико ниједан од наведених поступака не буде успешан, као резервна операција примењује се замена атома.

Инсерција подразумева додавање атома или функционалне групе у постојећу SMILES ниску. Најпре се из унапред дефинисаног скупа могућих уметања насумично одабира један атом или функционална група, након чега се насумично бира позиција у SMILES ниски на коју ће бити извршено уметање. Будући да произвољно уметање може довести до невалидне молекулске структуре, добијена SMILES ниска се након сваког покушаја проверава. Поступак се понавља до унапред дефинисаног броја покушаја, све док се не добије валидна структура. Уколико ниједан покушај не буде успешан, примењује се резервна операција делеције.

SELFIES мутација

SELFIES мутација се реализује над SELFIES репрезентацијом молекула, чиме се омогућава измена молекулске структуре на нивоу њених токена. Најпре се улазна молекулска структура преводи из SMILES у SELFIES запис, након чега се случајно бира једна од три врсте мутације: замена, уметање или брисање токена. Код замене се један токен замењује другим насумично изабраним токеном из дозвољене SELFIES азбуке, док се код уметања нови токен додаје на случајно изабрану позицију. Брисањем се, са друге стране, уклања један постојећи токен. Ова операција се примењује само ако молекул садржи више од једног токена. Измењени низ токена се затим декодира у SMILES запис. Уколико добијена структура није валидна или је идентична почетној структури, покушава се нова мутација, при чему је број покушаја ограничен. Уколико ниједан покушај не доведе до одговарајуће измене, примењује се резервна мутација - SMILES делеција.

Графовска мутација

Графовска мутација примењује се над графом молекула, описаном у поглављу 2.3. Могуће је извршити замену атома (што одговара промени чвора у графу) или замену везе (што одговара промени гране у графу). У случају замене атома, насумично се бира атом и замењује са произвољним атомом, из унапред дефинисаног скупа атома. Замена везе подразумева промену њене

вишеструкости - насумично одабрана веза мења се једноструком или двоструком везом. Ниједна од наведених графовских мутација не улаже напор да произведе валидну молекулску структуру, већ измене обавља механички, без провере хемијског контекста. Сваки кандидат се проверава RDKit санитизацијом, а одбацује се ако није валидан или је идентичан полазном молекулу. Због тога се овај поступак понавља до унапред дефинисаног броја покушаја, а ако ни тада не успемо да мутирамо молекул, примењује се резервна мутација - SMILES делеција.

BRICS мутација

BRICS мутација заснива се на BRICS декомпозицији молекула, замени насумично одабраног фрагмента молекулске структуре другим и поновној BRICS композицији добијеног скупа фрагмената, након чега се насумично бира једна од добијених могућих структура. Фрагмент за замену је на случајан начин одабран из скупа фрагмената који је добијен BRICS декомпозицијом свих молекула из прве генерације генетског алгорита, заједно са неколицином референтних молекула. Резултујући молекул се проверава и санитизује, а поступак се понавља уколико структура није валидна или је идентична полазном молекулу. Уколико ни након ограниченог броја покушаја није могуће добити одговарајућу структуру, примењује се SMILES делеција као резервна мутација.

Глава 5

Графички интерфејс и архитектура

The screenshot displays a web-based interface for drug discovery, titled "Drug Discovery". It is divided into several sections:

- Catalogue:** A grid of six chemical structures. The first three are highlighted with green borders. Below each structure is its ChemBL ID and pIC50 value:
 - CHEMBL5434495, pIC50: 10.1311
 - CHEMBL5597724, pIC50: 9.2770
 - CHEMBL4279016, pIC50: 9.1798
- Selected for first generation:** A section with two chemical structures, each with its ChemBL ID and pIC50 value:
 - CHEMBL474141, pIC50: 8.9996
 - CHEMBL3759356, pIC50: 8.0558
- Fitness:** A section on the right with radio buttons for different fitness metrics:
 - ☐ QED (weighted)
 - ☒ Random Forest (pIC50)
 - ☐ LightGBM (pIC50)
 - ☐ Ridge (pIC50)
- Random Forest (pIC50):** A detailed view of the selected model's performance:
 - Fitness score:** = predicted pIC50 (higher is better). Scaffold-split test metrics below.
 - Test (refit on train+val):**
 - RMSE: 0.8873
 - MAE: 0.6547
 - R²: 0.5781
 - Pearson: 0.7700
 - Validation (tuning selection):**
 - RMSE: 0.9782
 - MAE: 0.7173
 - R²: 0.5025
 - Pearson: 0.7153
 - Hyperparameters:**
 - max_depth: 60
 - max_features: 0.3
 - min_samples_leaf: 1
 - n_estimators: 800
 - Fingerprint:** Morgan r=2, 2048 bits (chirality=on)
 - Model:** random_forest_best.joblib
 - Tuning log:** tuning_history_random_forest.csv
- Add molecule to catalogue:** A form with input fields for "SMILES...", "Name or description (optional)", and a green "Add to catalogue" button.
- Continue:** A green button at the bottom right.

Слика 5.1: Граф прелаза између хетероатома и њихове вероватноће

Глава 6

Експериментални резултати

Глава 7

Дискусија

Глава 8

Закључак

Литература

- [1] Guy W. Bemis and Mark A. Murcko. The properties of known drugs. 1. molecular frameworks. *Journal of Medicinal Chemistry*, 39(15):2887--2893, July 1996.
- [2] G. Richard Bickerton, Gaia V. Paolini, Jérémy Besnard, Sorel Muresan, and Andrew L. Hopkins. Quantifying the chemical beauty of drugs. *Nature Chemistry*, 4(2):90--98, 2012.
- [3] Jörg Degen, Christof Wegscheid-Gerlach, Andrea Zaliani, and Matthias Rarey. On the art of compiling and using ‘Drug-Like’ chemical fragment spaces. *ChemMedChem*, 3(10):1503--1507, 2008.
- [4] Mario Krenn, Florian Häse, AkshatKumar Nigam, Pascal Friederich, and Alán Aspuru-Guzik. Self-referencing embedded strings (SELFIES): A 100% robust molecular string representation. *Machine Learning: Science and Technology*, 1(4):045024, October 2020.
- [5] Gregory Landrum. RDKit: Open-source cheminformatics, May 2006. <https://www.rdkit.org>.
- [6] Thanh-Hoang Nguyen-Vo, Paul Teesdale-Spittle, Joanne Harvey, and Binh Nguyen. Molecular representations in bio-cheminformatics. *Memetic Computing*, 16:519--536, July 2024.
- [7] David Rogers and Mathew Hahn. Extended-connectivity fingerprints. *Journal of Chemical Information and Modeling*, 50(5):742--754, May 2010.
- [8] David Weininger. SMILES, 1. introduction and encoding rules. *Journal of Chemical Information and Computer Sciences*, 28(1):31--36, 1988.

Биографија аутора

Вук Стефановић Караџић (*Тршић, 26. октобар/6. новембар 1787. — Беч, 7. фебруар 1864.*) био је српски филолог, реформатор српског језика, сакупљач народних умотворина и писац првог речника српског језика. Вук је најзначајнија личност српске књижевности прве половине XIX века. Стекао је и неколико почасних доктората. Учествовао је у Првом српском устанку као писар и чиновник у Неготинској крајини, а након слома устанка преселио се у Беч, 1813. године. Ту је упознао Јернеја Копитара, цензора словенских књига, на чији је подстицај кренуо у прикупљање српских народних песама, реформу ћирилице и борбу за увођење народног језика у српску књижевност. Вуковим реформама у српски језик је уведен фонетски правопис, а српски језик је потиснуо славеносрпски језик који је у то време био језик образованих људи. Тако се као најважније године Вукове реформе истичу 1818., 1836., 1839., 1847. и 1852.